

Sprawozdanie z empirycznej analizy algorytmów sortowania

Tymon Kwiatkowski - 319272

Konrad Kotlicki - 310958

Adam Fedorowicz - 319266

Styczeń 2022

Przedmiot: Algorytmy i Struktury Danych

Kierunek: Geoinformatyka

Rok Akademicki: 2021/2 semestr I

Tytuł Ćwiczenia: Sortowanie Shella a sortowanie przez scalanie

Spis treści

1	Wstęp	1
1.1	Przedstawienie celu zadania	1
2	Analiza Algorytmów	2
2.1	Sortowanie Shella	2
a)	Omówienie działania algorytmu	2
b)	Złożoność czasowa	2
c)	Kod użyty w badaniu	2
2.2	Sortowanie przez Scalanie	3
a)	Omówienie działania algorytmu	3
b)	Złożoność czasowa	3
c)	Kod użyty w badaniu	3
3	Sortowanie Shella a sortowanie przez scalanie	4
3.1	Przebieg ćwiczenia	4
3.2	Empiryczna analiza algorytmów	4
3.3	Dla jakich wielkości tablicy sortowanie Shella działa z porównywalną prędkością?	6
3.4	W jakich warunkach lepiej jest wykorzystać sortowanie Shell-a? Oraz do jakich zastosowań?	6

1 Wstęp

1.1 Przedstawienie celu zadania

Celem badania jest zaimplementowanie oraz zaobserwowanie różnic między sortowaniem Shella, a sortowaniem przez scalanie.

Do tego celu przeprowadzone zostały testy działania tych algorytmów na tablicach:

- losowych
- posortowanych
- posortowanych malejąco
- prawie posortowanych

O liczbie elementów wynoszącej od **50 tys** do **10 mln**.

Wyniki tych testów mają nam również pomóc w odpowiedzeniu na poniższe pytania:

- Dla jakich wielkości tablicy sortowanie Shella działa z porównywalną prędkością, co sortowanie przez scalanie?
- W jakich warunkach lepiej jest wykorzystać sortowanie Shella? Oraz do jakich zastosowań?

2 Analiza Algorytmów

2.1 Sortowanie Shella

a) Omówienie działania algorytmu

Sortowanie Shella bazuje na zasadzie podziału dużego problemu na mniejsze, łatwiejsze do rozwiązania. Duża tablica danych do posortowania jest dzielona na mniejsze rozłączne tablice zawierające, co h -ty element. W tak przygotowanych tablicach algorytm sortuje elementy sortowaniem przez wstawianie. Następnie algorytm wykonuje tę samą operację, jednakże tym razem dla mniejszego h , aż do $h = 1$.

b) Złożoność czasowa

Efektywność tego algorytmu zależy w dużym stopniu od przyjętego wzoru na ciąg wartości h . W pierwszej wersji tego algorytmu wzór ten wyglądał następująco $h = \frac{1}{2}(k - 1)$ oraz dawał złożoność czasową $\Theta(N^2)$. W tym zadaniu wykorzystany został wzór $h = \frac{1}{2}(3k - 1)$, którego złożoność czasowa jest wyrażona przez $\Theta(N^{\frac{3}{2}})$.

c) Kod użyty w badaniu

```
1 // Exchanges values
2 inline void exch(int a[], int i, int j)
3 {
4     int t = a[i];
5     a[i] = a[j];
6     a[j] = t;
7 }
8
9 // shell sort
10 void shell_sort(int a[], int size)
11 {
12     int h = 1;
13     while (h < size / 3)
14     {
15         h = 3 * h + 1; // 1, 4, 13, 40, 121, 364, ...
16     }
17
18     while (h >= 1)
19     {
20         for (int i = h; i < size; i++)
21         {
22             for (int j = i; j >= h; j -= h)
23             {
24                 if (a[j] < a[j - h])
25                 {
26                     exch(a, j, j - h);
27                 }
28                 else
29                 {
30                     break;
31                 }
32             }
33         }
34
35         h /= 3;
36     }
37 }
```

2.2 Sortowanie przez Scalanie

a) Omówienie działania algorytmu

Podobnie do Sortowania Shella sortowanie przez scalanie zasadzie "dziel i zwyciężaj", łatwiejsze do rozwiązania. Tablica wejściowych do posortowania jest dzielona na dwie części. Następnie dla każdej części wywoływane jest rekurencyjnie sortowanie przez scalanie. Gdy algorytm posortuje obie części, dwie takie tablice są scalane w jedną wyjściową, która jest już posortowana.

b) Złożoność czasowa

Złożoność obliczeniowa algorytmu jest jednakowa dla przypadku najlepszego, średniego i najgorszego, i wynosi $\Theta(N \log(N))$.

c) Kod użyty w badaniu

```
1 // merge operation
2 void merge(int a[], int aux[], int lo, int mid, int hi)
3 {
4     // copy
5     for (int k = lo; k <= hi; k++)
6     {
7         aux[k] = a[k];
8     }
9
10    // merge
11    int i = lo, j = mid + 1;
12    for (int k = lo; k <= hi; k++)
13    {
14        if (i > mid)                a[k] = aux[j++]; // left array empty
15        else if (j > hi)            a[k] = aux[i++]; // right array empty
16        else if (aux[j] < aux[i]) a[k] = aux[j++]; // right value lower
17        else                        a[k] = aux[i++]; // left value lower
18    }
19 }
20
21 // merge sort
22 void merge_sort(int a[], int aux[], int lo, int hi)
23 {
24     if (hi <= lo) return; // stop when nothing to sort
25     int mid = (lo + hi) / 2; // find middle
26
27     merge_sort(a, aux, lo, mid); // sort left half
28     merge_sort(a, aux, mid + 1, hi); // sort right half
29     merge(a, aux, lo, mid, hi); // merge arrays
30 }
31
32 // merge sort
33 void merge_sort(int a[], int size)
34 {
35     int* aux = new int[size];
36     merge_sort(a, aux, 0, size - 1);
37     delete[] aux;
38 }
```

3 Sortowanie Shella a sortowanie przez scalanie


3.1 Przebieg ćwiczenia

Wygenerowaliśmy 800 plików z danymi o łącznym rozmiarze 29,1 GB. Po 200 tablic każdego z wymienionych we wstępie rodzajów. Tak wygenerowane zbiory posortowaliśmy obydwoma algorytmami oraz zmierziliśmy czas każdego przypadku. Następnie na bazie tych danych stworzyliśmy wykresy, dzięki którym zaobserwowaliśmy zależności między sortowaniem Shella, a sortowaniem przez scalanie.


3.2 Empiryczna analiza algorytmów

Poniżej umieściliśmy wykresy przedstawiające czas w sekundach jaki zajęło algorytmom posortowanie tablic liczb o rosnącej liczbie elementów.


Rysunek 1:




Rysunek 2:



Rysunek 3:
Shell Sort kontra Merge sort na danych malejących



Rysunek 4:
Shell Sort kontra Merge sort na danych częściowo posortowanych



Jak możemy zauważyć z wykresów algorytm sortowania Shella, (w większości testowanych przypadków) działa w krótszym czasie od sortowania przez scalanie. Zasada ta jest prawdziwa dla zbiorów danych posortowanych rosnąco, zbiorów danych częściowo posortowanych oraz zbiorów danych posortowanych malejąco (gdzie różnica czasu wykonania jest stosunkowo niewielka). Wśród przeprowadzonych testów można zauważyć, że dla zbiorów danych losowych sortowanie przez scalanie wykonuje się w złożoności czasowej $N \log(N)$ podczas, gdy sortowanie Shella zbliża się do swojej złożoności pesymistycznej - mN^k .

3.3 Dla jakich wielkości tablicy sortowanie Shella działa z porównywalną prędkością?

Sortowanie Shella działa porównywalnie szybko do sortowania przez scalanie jedynie w przypadku sortowania zbiorów danych posortowanych malejąco (jak na wykresie 3). Przy takich zbiorach sortowanie przez scalanie, mimo że wolniejsze, jest wciąż stosunkowo bliskie sortowaniu Shella. Różnice te wynoszą co najwyżej 0,3 sekundy nawet dla największych z testowanych zbiorów.

3.4 W jakich warunkach lepiej jest wykorzystać sortowanie Shell-a? Oraz do jakich zastosowań?

Sortowanie Shella sprawdzi się lepiej od sortowania przez scalanie kiedy:

- nasze dane są już częściowo posortowane,
- nie mamy do dyspozycji dodatkowej pamięci,
- zależy nam na prostocie działania algorytmu.

Z uwagi na te różnice sortowanie Shella bywa stosowane zamiast sortowania szybkiego w implementacjach funkcji `qsort` z biblioteki standardowej języka C przeznaczonych dla systemów wbudowanych. Ponadto algorytm ten był również wykorzystywany w jądrze systemu operacyjnego Linux do 2017 oraz w programie `bzip2`, służącym do bezstratnej kompresji danych.